

Adaboost

35

输入: 训练集 $D = \{(\mathbf{x}_1, y_1), (\mathbf{x}_2, y_2), \dots, (\mathbf{x}_m, y_m)\}$;
基学习算法 \mathcal{L} ;
训练轮数 T .

过程:

- 1: $\mathcal{D}_1(\mathbf{x}) = 1/m$.
- 2: **for** $t = 1, 2, \dots, T$ **do**
- 3: $h_t = \mathcal{L}(D, \mathcal{D}_t)$;
- 4: $\epsilon_t = P_{\mathbf{x} \sim \mathcal{D}_t}(h_t(\mathbf{x}) \neq f(\mathbf{x}))$;
- 5: **if** $\epsilon_t > 0.5$ **then break**
- 6: $\alpha_t = \frac{1}{2} \ln \left(\frac{1-\epsilon_t}{\epsilon_t} \right)$;
- 7:
$$\begin{aligned} \mathcal{D}_{t+1}(\mathbf{x}) &= \frac{\mathcal{D}_t(\mathbf{x})}{Z_t} \times \begin{cases} \exp(-\alpha_t), & \text{if } h_t(\mathbf{x}) = f(\mathbf{x}) \\ \exp(\alpha_t), & \text{if } h_t(\mathbf{x}) \neq f(\mathbf{x}) \end{cases} \\ &= \frac{\mathcal{D}_t(\mathbf{x}) \exp(-\alpha_t f(\mathbf{x}) h_t(\mathbf{x}))}{Z_t} \end{aligned}$$
- 8: **end for**

输出: $H(\mathbf{x}) = \text{sign} \left(\sum_{t=1}^T \alpha_t h_t(\mathbf{x}) \right)$

Adaboost

36

例 给定如下表所示训练数据。假设个体学习器由 x （输入）和 y （输出）产生，其阈值 v （判定正反例的分界线）使该分类器在训练数据集上分类误差率最低。（ $y=1$ 为正例， $y=-1$ 为反例）

序号	1	2	3	4	5	6	7	8	9	10
x	0	1	2	3	4	5	6	7	8	9
y	1	1	1	-1	-1	-1	1	1	1	-1

第一个个体学习器：

我们首先认为 x_i ($i=1,2,\dots,10$) 的权重是一样的，即每一个数据同等重要。（权重是用来计算误差的）

D_1

x	0	1	2	3	4	5	6	7	8	9
w	0.1	0.1	0.1	0.1	0.1	0.1	0.1	0.1	0.1	0.1
y	1	1	1	-1	-1	-1	1	1	1	-1

(a) 在权值分布为 D_1 的训练数据上，阈值 v 取2.5（红线）时分类误差率最低（此时 $x=6,7,8$ 的数据被错分为反例，误差为它们的权重之和 $e_1 = 0.1+0.1+0.1=0.3$ ，误差率小于 $\frac{1}{9}$ 才有意义），故

Adaboost

37

个体学习器为 $G_1(x) = \begin{cases} 1 & x < 2.5, \\ -1 & x > 2.5. \end{cases}$

(b) 根据误差 e_1 计算系数 $\alpha_1 = 0.4236$ (公式: $\alpha_i = \frac{1}{2} \log \frac{1 - e_i}{e_i}$, 可以发现只有当 $e_i < \frac{1}{2}$ 时, $\alpha_i > 0$, 这样个体学习器才是有意义的)

(c) 更新训练数据的权值分布 (公式:

$$w_{m+1,i} = \frac{w_{m,i}}{Z_m} \exp(-\alpha_m y_i G_m(x_i)), i = 1, 2, \dots, N,$$

$$Z_m = \sum_{i=1}^N w_{m,i} \exp(-\alpha_m y_i G_m(x_i)), Z_m \text{ 是为了保证每次权值总和为1})$$

(通过指数损失函数 $\exp(x)$ 调整权重, 分类正确的降低权重(y_i 和 $G_m(x_i)$ 同号则 $y_i G_m(x_i) > 0$, $-\alpha_m y_i G_m(x_i) < 0$), 分类错误的增加权重):

Adaboost

38

```
>>> import math
>>> a = 0.5*math.log((1-0.3)/0.3, math.e)
>>> a
0.42364893019360184
```

```
>>> zm=0.1*math.e**(-0.4236)*7+0.1*math.e**(0.4236)*3
>>> zm
0.9165151400883117
>>> w1 = 0.1/zm*math.e**(-0.4236)
>>> w2 = 0.1/zm*math.e**(0.4236)
>>> w1,w2
(0.07143206644239734, 0.1666585116344062)
```

Adaboost

D_2 (权重之和始终为1)

39

x	0	1	2	3	4	5	6	7	8	9
w	0.07143	0.07143	0.07143	0.07143	0.07143	0.07143	0.16667	0.16667	0.16667	0.07143
y	1	1	1	-1	-1	-1	1	1	1	-1

可以看到 $x=6,7,8$ 的数据的权重变大了, 而其他数据的权重降低了, 这是希望能把之前经常分类错误 (经常分类错误会出现权重不断变大) 的数据能在下一个个体学习器分类正确 (记住: 权重是用来计算误差的, 为了降低误差, 选择阈值时会倾向把权重大的分类正确)

$$f_1(x) = \alpha_1 G_1(x) = 0.4236 G_1(x)$$

$$0.4236 G_1(x) = \begin{cases} 0.4236 * 1 & x < 2.5, \\ 0.4236 * (-1) & x > 2.5. \end{cases}$$

$$\text{sign}[f_1(x)] = \begin{cases} 1 & x < 2.5, \\ -1 & x > 2.5. \end{cases}$$

集成学习器 $\text{sign}[f_1(x)]$ (第一次集成, 只有一个个体学习器) 在训练数据集上有3个误分类点

Adaboost

40

第二个个体学习器:

D_2

```
>>> a = 0.5*math.log((1-0.2143)/0.2143, math.e)
>>> a
0.6495990688511224
```

x	0	1	2	3	4	5	6	7	8	9
w	0.07143	0.07143	0.07143	0.07143	0.07143	0.07143	0.16667	0.16667	0.16667	0.07143
y	1	1	1	-1	-1	-1	1	1	1	-1

(a) 在权值分布为 D_2 的训练数据上, 阈值 v 取8.5时分类误差率最低 (此时 $x=3,4,5$ 的数据被错分为正例, 误差为它们的权重之和 $e_2 = 0.07143 + 0.07143 + 0.07143 = 0.2143$, 误差率降低了!),

故个体学习器为 $G_2(x) = \begin{cases} 1 & x < 8.5, \\ -1 & x > 8.5. \end{cases}$

(b) 根据误差 e_2 计算系数 $\alpha_2 = 0.6496$

(c) 更新训练数据的权值分布 (在 D_2 的基础上调整 D_3 , 分类正确的降低权重, 分类错误的增加权重) :

Adaboost

D_3

x	0	1	2	3	4	5	6	7	8	9
w	0.0455	0.0455	0.0455	0.16667	0.16667	0.16667	0.1060	0.1060	0.1060	0.0455
y	1	1	1	-1	-1	-1	1	1	1	-1

对比 D_2 可以看到 $x=3,4,5$ 的数据的权重变大了，而其他权重降低了。

$$0.4236G_1(x) = \begin{cases} 0.4236 * 1 & x < 2.5, \\ 0.4236 * (-1) & x > 2.5. \end{cases}$$

$$0.6496G_2(x) = \begin{cases} 0.6496 * 1 & x < 8.5, \\ 0.6496 * (-1) & x > 8.5. \end{cases}$$

$$f_2(x) = \alpha_1 G_1(x) + \alpha_2 G_2(x) = 0.4236G_1(x) + 0.6496G_2(x)$$

$$f_2(x) = \begin{cases} 0.4236 * 1 + 0.6496 * 1 = 1.0732 & x < 2.5, \\ 0.4236 * (-1) + 0.6496 * 1 = 0.226 & 2.5 < x < 8.5, \text{ (注意:} \\ 0.6496 * (-1) = -0.6496 & x > 8.5, \end{cases}$$

$x < 2.5$ 时, 也 < 8.5)

$$\text{sign}[f_2(x)] = \begin{cases} 1 & x < 8.5, \\ -1 & x > 8.5. \end{cases}$$

Adaboost

42

D_3

x	0	1	2	3	4	5	6	7	8	9
w	0.0455	0.0455	0.0455	0.16667	0.16667	0.16667	0.1060	0.1060	0.1060	0.0455
y	1	1	1	-1	-1	-1	1	1	1	-1

(a) 在权值分布为 D_3 的训练数据上, 阈值 v 取5.5时分类误差率最低 ($e_3 = 0.1820$, 误差率又降低了! $x=0,1,2,9$ 被分类错误), 故个体学习器为 $G_3(x) = \begin{cases} -1 & x < 5.5, \\ 1 & x > 5.5. \end{cases}$

(b) 根据误差 e_3 计算系数 $\alpha_3 = 0.7514$

(c) 更新训练数据的权值分布:

Adaboost

D_4

43

x	0	1	2	3	4	5	6	7	8	9
w	0.125	0.125	0.125	0.102	0.102	0.102	0.065	0.065	0.065	0.125
y	1	1	1	-1	-1	-1	1	1	1	-1

$$f_3(x) = \alpha_1 G_1(x) + \alpha_2 G_2(x) + \alpha_3 G_3(x)$$

$$f_3(x) = \begin{cases} 0.3218 & x < 2.5, \\ -0.5254 & 2.5 < x < 5.5, \\ 0.9774 & 5.5 < x < 8.5, \\ -0.3218 & x > 8.5. \end{cases}$$

$$\text{sign}[f_3(x)] = \begin{cases} 1 & x < 2.5, \\ -1 & 2.5 < x < 5.5, \\ 1 & 5.5 < x < 8.5, \\ -1 & x > 8.5. \end{cases}$$

最终结果:

x	0	1	2	3	4	5	6	7	8	9
w	0.125	0.125	0.125	0.102	0.102	0.102	0.065	0.065	0.065	0.125
y	1	1	1	-1	-1	-1	1	1	1	-1

分类器 $\text{sign}[f_3(x)]$ 在训练数据集上有0个误分类点 (amazing!)


Adaboost

44


- 对比三个个体学习器可以发现，权值很低的数据从侧面说明，它们在前面的学习器经常被分类正确，也就是说它们被分类正确的票数就比较多（ α 相当于每个分类器的票数），那么之后的个体学习器把它们分类错也影响不大，反正总票数是分类正确的票数多就可以了。例如 $x=1$ ，前面两次分类对了，获得正确票数 $0.4236 + 0.6496 = 1.0732$ ，第三次错了，获得错误票数 0.7514 ，正确票数多，最终还是分类正确了。
- 为了想办法让分类错误的数据变为分类正确的，后面的个体学习器也在努力。如 $x=6$ ，第一次分类错误的票数为 0.4236 ，第二次分类正确的票数 0.6496 ，可以看到为了让前面分类错误的数据变为分类正确的，后面个体学习器的重要性（ α ）需要比前面的大。

Adaboost


45



(a) 3个基学习器



(b) 5个基学习器



(c) 11个基学习器